NLP

Word Embeddings

Docentes:
Josselyn Ordóñez
emails: josselynsofia@gmail.com

Segmentar y tokenizar

Proceso en el cual una oración o documento es segmentado en términos individuales. Una vez finalizada la segmentación cada término único es referenciado mediante un token.

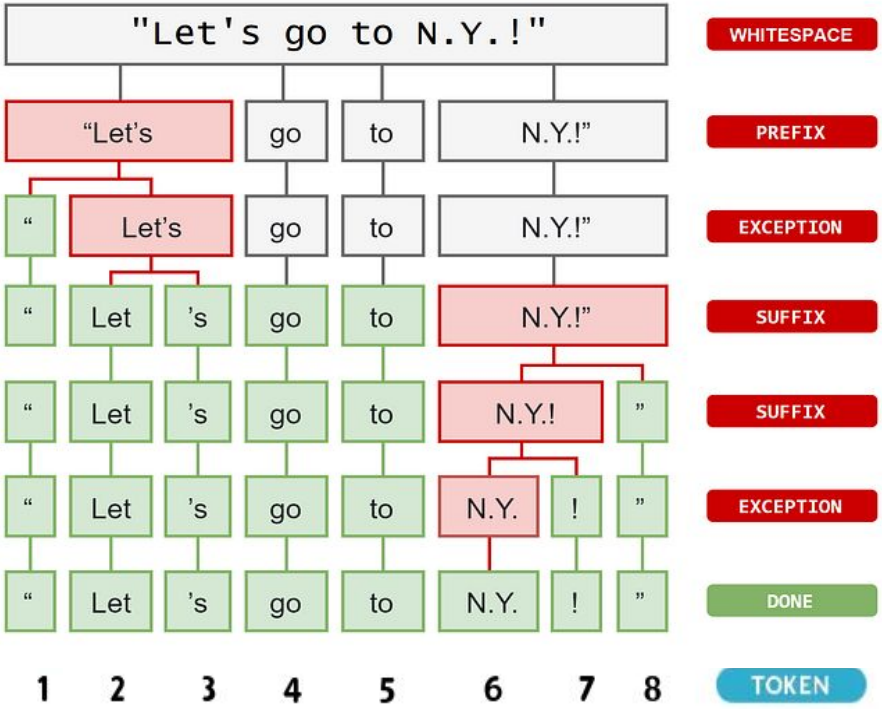

Problemas con CountVectorizer/OHE/TF-IDF

Textos de significado similar pueden ser “ortogonales”

Estoy viajando en colectivo

Voy arriba del bus

Ortogonal -> Similaridad coseno = 0

La dimensión de los vectores depende del tamaño del vocabulario

No aprovechamos la dimensionalidad

cat	the	quick	brown	fox	jumped	over	dog	bird	flew	...	kangaroo	house
0	1	0	0	0	0	0	0	0	0	...	0	0
0	0	1	0	0	0	0	0	0	0	...	0	0
0	0	0	1	0	0	0	0	0	0	...	0	0
0	0	0	0	1	0	0	0	0	0	...	0	0
0	0	0	0	0	1	0	0	0	0	...	0	0
0	0	0	0	0	0	1	0	0	0	...	0	0
0	1	0	0	0	0	0	0	0	0	...	0	0
0	0	0	1	0	0	0	0	0	0	...	0	0
0	0	0	0	0	0	0	1	0	0	...	0	0

time

Dictionary Size

Embeddings

Un embedding es una representación densa de palabras en un espacio vectorial continuo.

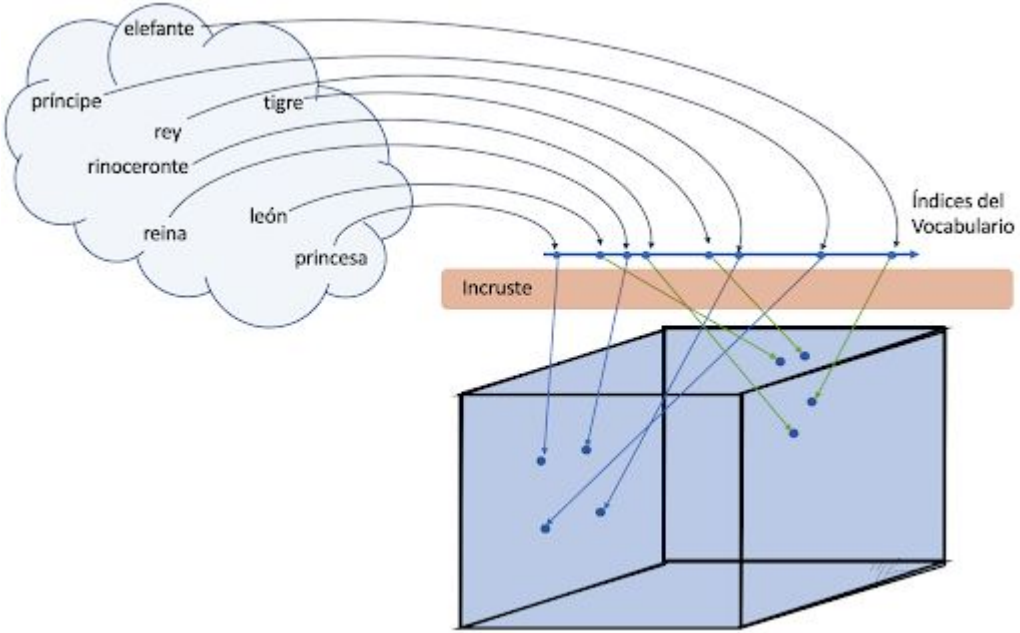

Propiedades buscadas:

1. ***Representación compacta***
2. ***Similaridad semántica***
3. ***Comprensión de contexto***

Atributos como dimensiones

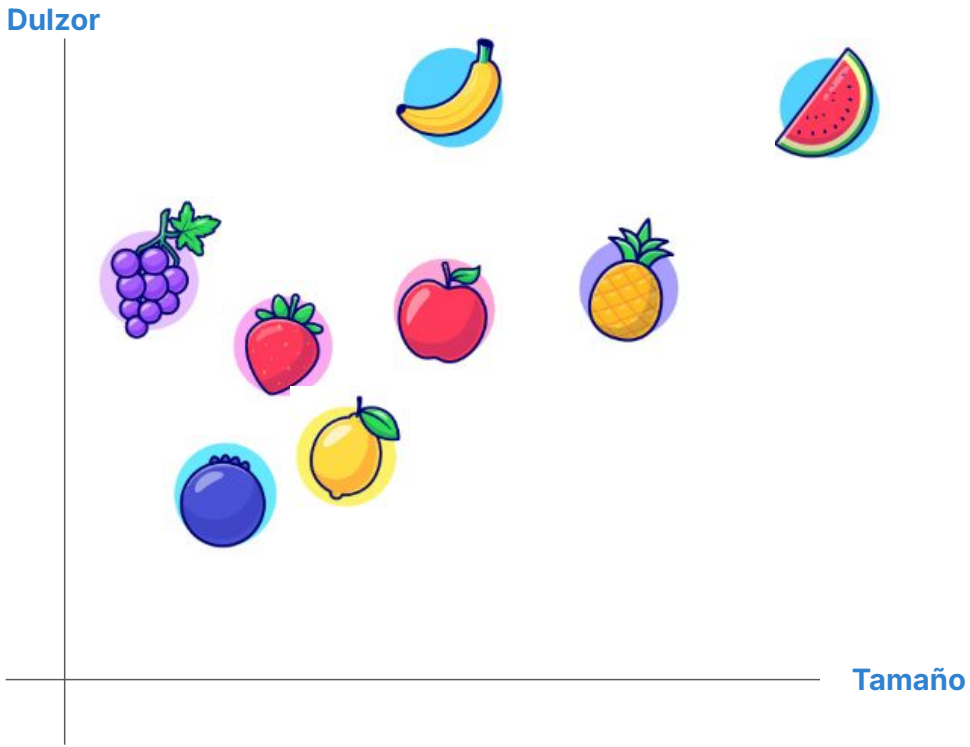

Atributos como dimensiones

	Dulzor	Tamaño	Rojo	Tropical	Circular
	4	3	10	3	3
	10	10	0	10	6
	3	1	0	2	10
	5	5	10	2	7
	7	7	0	7	2

Evolución de embeddings

Word2Vec (2013)

- **Creador:** Google
- **Hito:** Es el momento en que los vectores se vuelven "famosos".
- **Aporte:** Introducen las arquitecturas **CBOW** y **Skip-gram**.

Fast Text (2016)

- **Creador:** Facebook
- **Hito:** Resuelven el problema de las palabras desconocidas.
- **Aporte:** n-grams de caracteres.

Glove (2014)

- **Creador:** Universidad de Stanford
- **Hito:** Incorpora estadísticas globales de todo el texto.
- **Aporte:** matriz de co-ocurrencias de todo el corpus.

ELMo / BERT (2018+)

- **Creador:** Allen Institute (ELMo) y Google (BERT)
- **Hito:** embeddings dinámicos.
- **Aporte:** pasamos de word embeddings a contextual embeddings.

Word2Vec

Es una técnica publicada por **Google en 2013** que revolucionó la Inteligencia Artificial. Su gran descubrimiento fue que podíamos enseñarles a las máquinas el **significado** de las palabras simplemente haciéndolas "leer" mucho texto, sin diccionarios.

Antes: Las palabras eran etiquetas aisladas (IDs).

Con Word2Vec: Las palabras son **vectores** (flechas o coordenadas) en un espacio de muchas dimensiones.

La hipótesis distributiva: "Conocerás a una palabra por las compañías que tiene"

Word Embeddings

Las palabras que tienen un significado similar tendrán una representación similar como embeddings

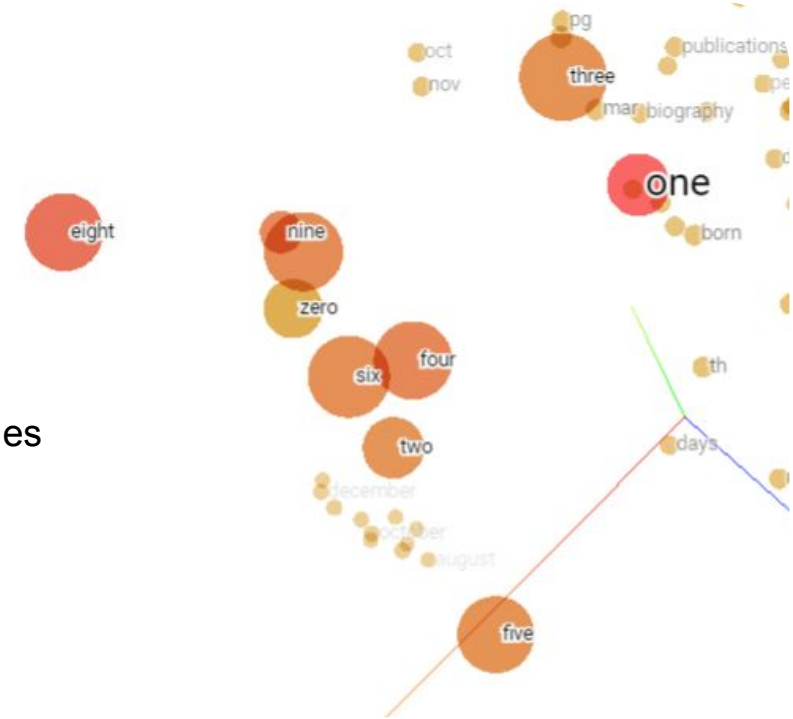

http://projector.tensorflow.org/

Veremos una proyección en 3 dimensiones de los embeddings multidimensionales.

GloVe y fastText

Embeddings pre-entrenados basados en diferentes enfoques:

GloVe

- Tokenización basada en palabras
- Entrenado con textos de Wikipedia, Common Crawl y GigaWord 5
- Se basa en calcular la matriz de co-ocurrencia de palabras y estimar el cociente de probabilidad de aparición.

fastText

- Tokenización basada en N-Grams de caracteres (3 a 6). Mejora la interpretación de sufijos y prefijos
- Entrenado con una colección de 8 corpus (portales de noticias, reviews, WIkipedia)
- Basado en word2vec (CBOW/Skip-Gram)
- Puede crear un embedding de una palabra que nunca vió

Matriz de co-ocurrencia

Obtención del corpus: Reuní las letras de sus canciones desde fuentes en línea, como letras.top y Buenamusica.com.

Preprocesamiento del texto:

- Convertir todo el texto a minúsculas.
- Eliminar signos de puntuación.
- Tokenizar el texto para dividirlo en palabras individuales.
- Eliminar palabras vacías comunes en español, como "el", "la", "y", etc.

Cálculo de frecuencias: Contar la frecuencia de cada palabra y seleccioné las 10 más comunes.

Construcción de la matriz de co-ocurrencia:

- Definir una ventana de contexto de 5 palabras alrededor de cada término.
- Contar cuántas veces cada par de palabras apareció dentro de la misma ventana.

	amor	vida	luz	sol	piel	alma	tiempo	ojos	corazón	cielo
amor	0	15	12	10	8	14	9	11	13	10
vida	15	0	11	9	7	13	8	10	12	9
luz	12	11	0	8	6	10	7	9	11	8
sol	10	9	8	0	5	9	6	8	10	7
piel	8	7	6	5	0	7	4	6	8	5
alma	14	13	10	9	7	0	8	11	13	10
tiempo	9	8	7	6	4	8	0	7	9	6
ojos	11	10	9	8	6	11	7	0	12	9
corazón	13	12	11	10	8	13	9	12	0	10
cielo	10	9	8	7	5	10	6	9	10	0

GloVe y fastText

Embeddings pre-entrenados basados en diferentes enfoques:

GloVe

- Tokenización basada en palabras
- Entrenado con textos de Wikipedia, Common Crawl y GigaWord 5
- Se basa en calcular la matriz de co-ocurrencia de palabras y estimar el cociente de probabilidad de aparición.

fastText

- Tokenización basada en N-Grams de caracteres (3 a 6). Mejora la interpretación de sufijos y prefijos
- Entrenado con una colección de 8 corpus (portales de noticias, reviews, WIkipedia)
- Basado en word2vec (CBOW/Skip-Gram)
- Puede crear un embedding de una palabra que nunca vió

N-GRAM

"Subsecuencia de N elementos de una secuencia dada"

Otra forma de agrupar las palabras distinto a word2vec (N=1, unigram) en donde se busca aumentar el poder de generalización y a su vez poder hacer más variado el vocabulario.

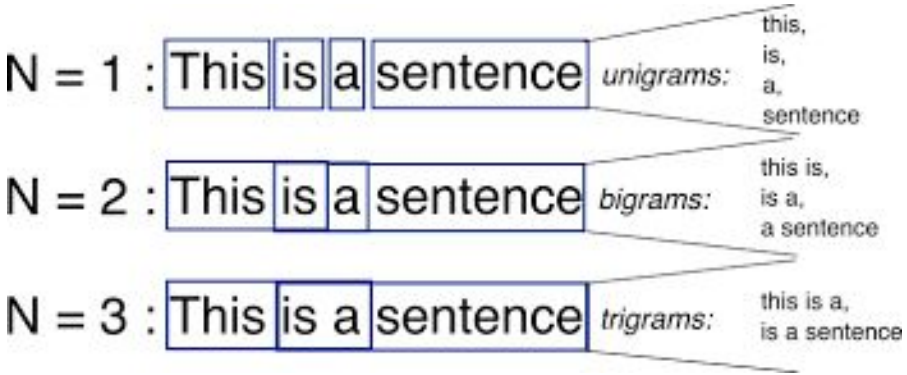

Character-level unigrams

Text	Token Sequence	Token Value
Dogs	1	D
Dogs	2	o
Dogs	3	g
Dogs	4	s

Character-level bigrams

Text	Token Sequence	Token Value
Dogs	1	Do
Dogs	2	og
Dogs	3	gs

Character-level trigrams

Text	Token Sequence	Token Value
Dogs	1	Dog
Dogs	2	ogs

N-gramas (por palabras)

Todas las hojas son del viento

Unigramas	Bigramas	Trigramas
“todas”	“todas las”	“Todas las hojas”
“las”	“las hojas”	“las hojas son”
“hojas”	“hojas son”	“hojas son del”
“son”	“son del”	“son del viento”
“del“	“del viento“	
“viento”		

N-gramas (por caracteres)

Todas las hojas son del viento

Unigramas	Bigramas	Trigramas
“t”	“to”	“Tod”
“o”	“od”	“oda”
“d”	“da”	“das”
“a”	“as”	“as ”
“s“	“…“	“…”
“….”		

En esta idea se basa fastText

Operaciones con Embeddings: tests de analogías

Una forma de testear la calidad de embeddings es probar su desempeño en tests de analogías:

París es a Francia lo que Madrid es a España.
Madrid y París corresponden a España y Francia

$$\overrightarrow{Paris} - \overrightarrow{Francia} \approx \overrightarrow{Madrid} - \overrightarrow{Espana}$$

$$simcos(\overrightarrow{Paris} - \overrightarrow{Francia}, \overrightarrow{Madrid} - \overrightarrow{Espana}) \approx 1$$

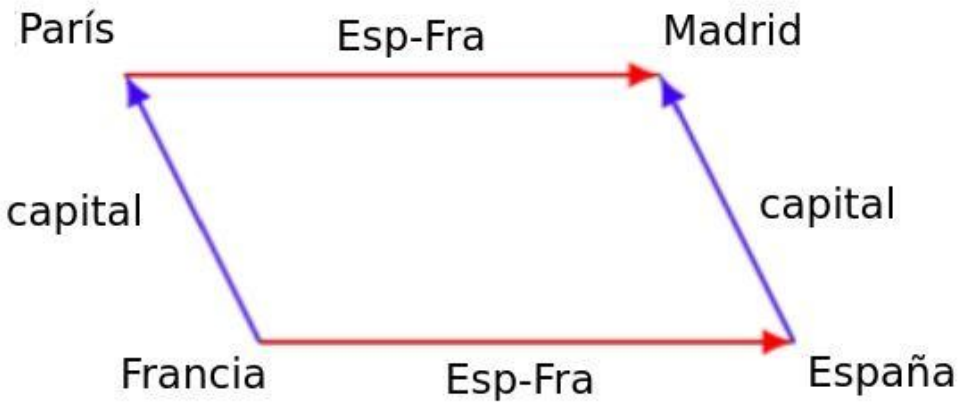

Embeddings Glove y Fasttext

Colab 2.a

Intervalo

CBOW (Continuous Bag of Words)

Adivinando la palabra por su contexto

El modelo recibe las palabras de alrededor (las "pistas") e intenta predecir cuál es la palabra que falta en el centro.

El _____ maúlla en el tejado.

Características clave:

- **Muchos a Uno:** Varias palabras de entrada → Una palabra de salida.
- **Velocidad:** Es muy rápido de entrenar.
- **Uso ideal:** Funciona mejor cuando tenemos mucha cantidad de texto y queremos capturar el significado general de palabras muy comunes.

¿Cómo podemos crear nuestros word Embeddings?

Aprendiendo (con redes neuronales) vectores para cada palabra que maximicen la relación entre las palabras de contexto y la palabra objetivo. Esto es lo que se implementó en la librería ***word2vec****.*

window

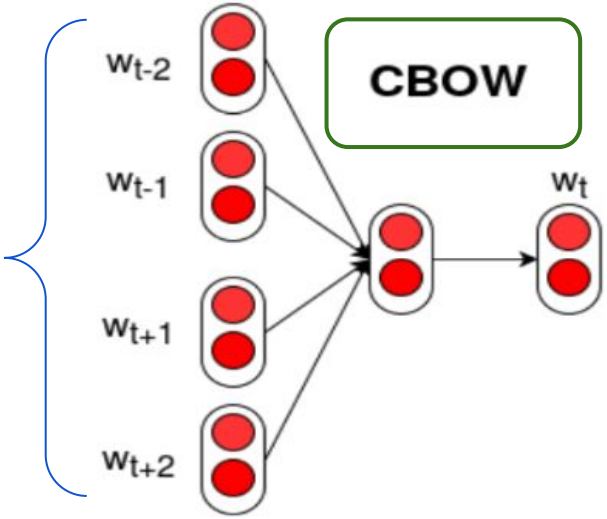

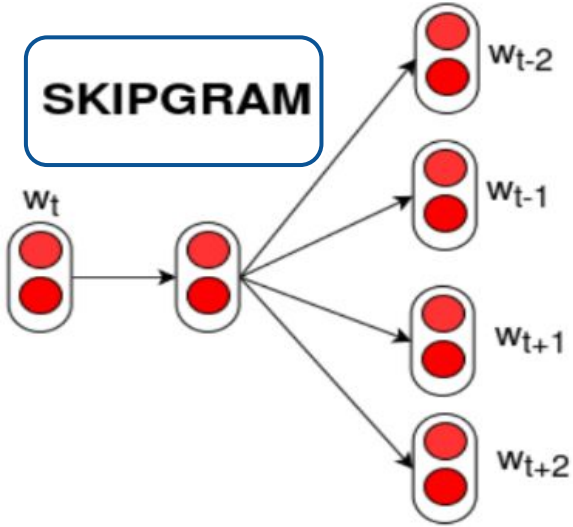

Se utiliza ***OneHotEncoding*** como representación del texto a la entrada del modelo

$$\frac{1}{T}\sum_{t=1}^{T}\sum_{-c\leq j\leq c, j\neq 0} logp(w_t|w_{t+j})$$

$$\frac{1}{T}\sum_{t=1}^{T}\sum_{-c\leq j\leq c, j\neq 0} logp(w_{t+j}|w_t)$$

LINK

Continuous Bag of Words Model (CBOW)

Utiliza como entrada el contexto de la palabra objetivo (palabras a izquierda y derecha de ella). El tamaño de la ventana determina cuántas palabras se tomarán para contextualizar el embedding.

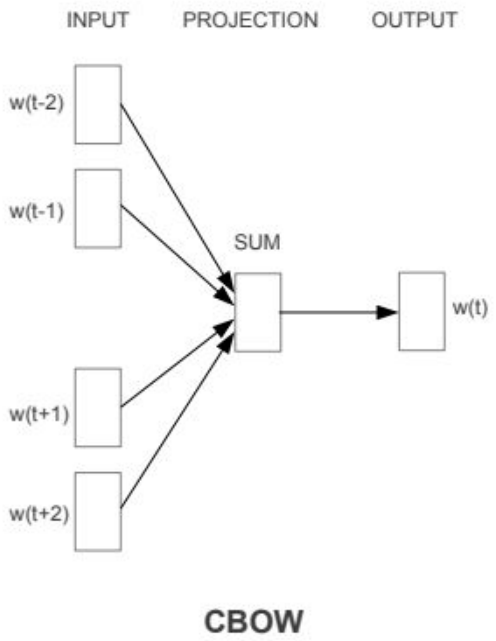

Continuous Bag of Words Model (CBOW)

Utiliza como entrada el contexto de la palabra objetivo (palabras a izquierda y derecha de ella). El tamaño de la ventana determina cuántas palabras se tomarán para contextualizar el embedding.

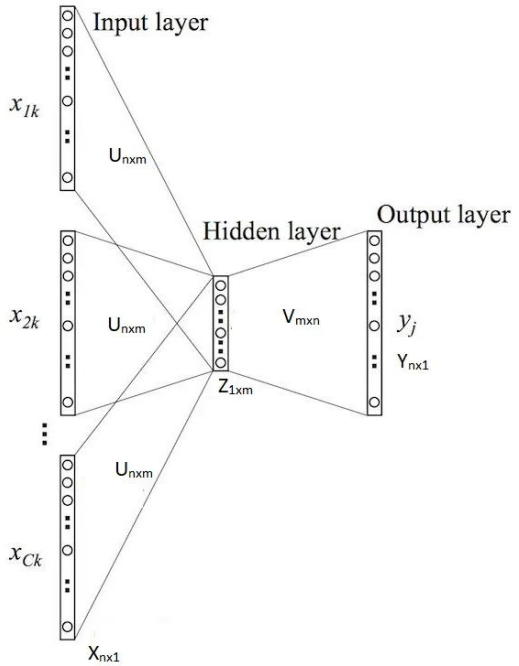

CBOW - Entrenamiento

LINK

Para entrenar necesitamos tener el vocabulario del corpus y las sentencias organizadas por el tamaño de la ventana de entrada.

Los embeddings de cada palabra son el embedding promedio de todas las veces que se utilizó en el corpus.

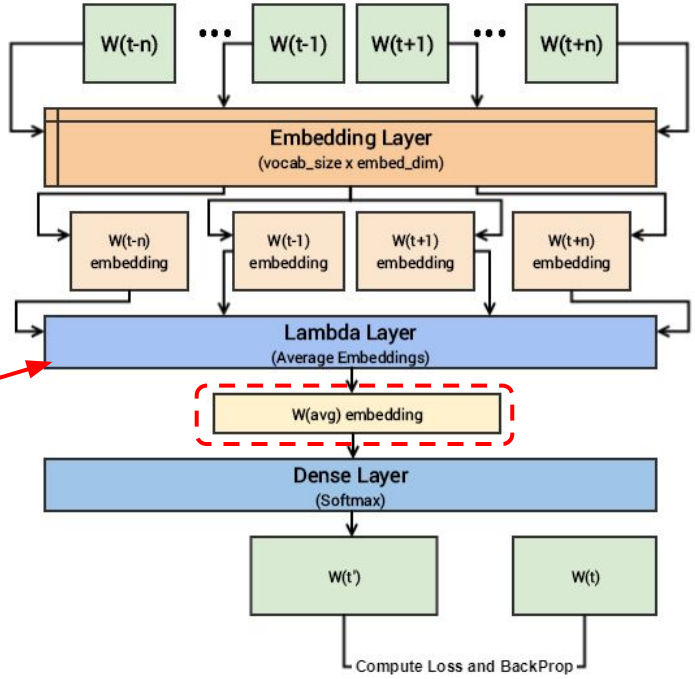


```
cbow = Sequential()
cbow.add(Embedding(input_dim=vocab_size, output_dim=embed_size, input_length=window_size*2))
cbow.add(Lambda(lambda x: K.mean(x, axis=1), output_shape=(embed_size,)))
cbow.add(Dense(vocab_size, activation='softmax'))
cbow.compile(loss='categorical_crossentropy', optimizer='rmsprop')
```

CBOW - Entrenamiento

Con tan solo un corpus de 12425 palabras distintas y embedding de 100 dimensiones hay que entrenar **2.5 Millones de parámetros**

```
_________________________________________________________________
Layer (type)                 Output Shape              Param #
=================================================================
embedding_1 (Embedding)      (None, 4, 100)            1242500
_________________________________________________________________
lambda_1 (Lambda)            (None, 100)               0
_________________________________________________________________
dense_1 (Dense)              (None, 12425)             1254925
=================================================================
Total params: 2,497,425
Trainable params: 2,497,425
Non-trainable params: 0
_________________________________________________________________
```

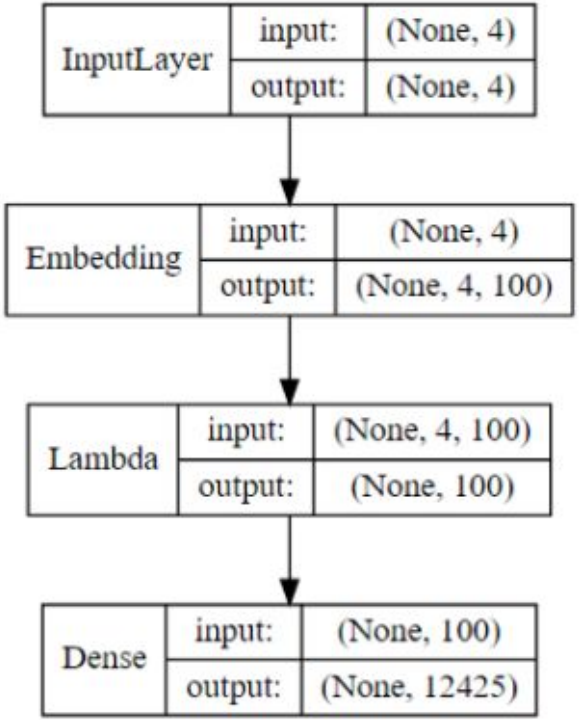

Skip-Gram

Adivinando el contexto por una palabra

Al contrario de CBOW, este modelo intenta predecir las palabras que rodean (contexto) a una palabra objetivo. Se divide el output como pares [target, context]

Características clave:

- **Uno a Muchos:** Una palabra de entrada → Varias palabras de contexto estimadas.
- **Precisión:** Es más lento que CBOW, pero mucho más preciso para palabras que no aparecen con frecuencia (palabras raras).
- **Uso ideal:** Es el preferido cuando el vocabulario es complejo o los datos no son gigantescos.

Skip-Gram

Al contrario de CBOW, este modelo intenta predecir las palabras que rodean (contexto) a una palabra objetivo. Se divide el output como pares [target, context]

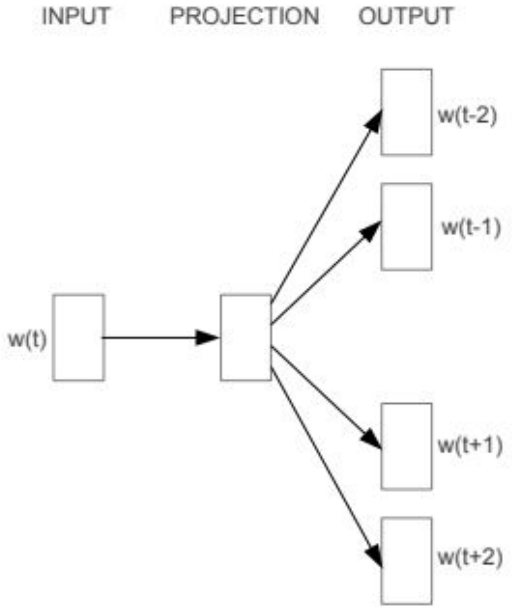

Skip-gram

I will have orange juice and eggs for breakfast	(will, I)	(will, have)	(will, orange)	
I will have orange juice and eggs for breakfast	(have, I)	(have, will)	(have, orange)	(have, juice)
I will have orange juice and eggs for breakfast	(orange, will)	(orange, have)	(orange, juice)	(orange, and)
I will have orange juice and eggs for breakfast	(juice, have)	(juice, orange)	(juice, and)	(juice, eggs)
I will have orange juice and eggs for breakfast	(and, orange)	(and, juice)	(and, eggs)	(and, for)
I will have orange juice and eggs for breakfast	(eggs, juice)	(eggs, and)	(eggs, for)	(eggs, breakfast)
I will have orange juice and eggs for breakfast	(for, and)	(for, eggs)	(for, breakfast)	

Skip-Gram - Entrenamiento

LINK

Por cada par [target, context] el sistema determina si las palabras tiene significado en contexto (1) o no lo tiene (0), buscando así acercar las palabras que tienen significado juntas (que se espera que estén juntas en el texto)

```
word_model = Sequential()
word_model.add(Embedding(vocab_size, embed_size,
                         embeddings_initializer="glorot_uniform",
                         input_length=1))
word_model.add(Reshape((embed_size, )))

context_model = Sequential()
context_model.add(Embedding(vocab_size, embed_size,
                  embeddings_initializer="glorot_uniform",
                  input_length=1))
context_model.add(Reshape((embed_size,)))

model = Sequential()
model.add(Merge([word_model, context_model], mode="dot"))
model.add(Dense(1, kernel_initializer="glorot_uniform", activation="sigmoid
```

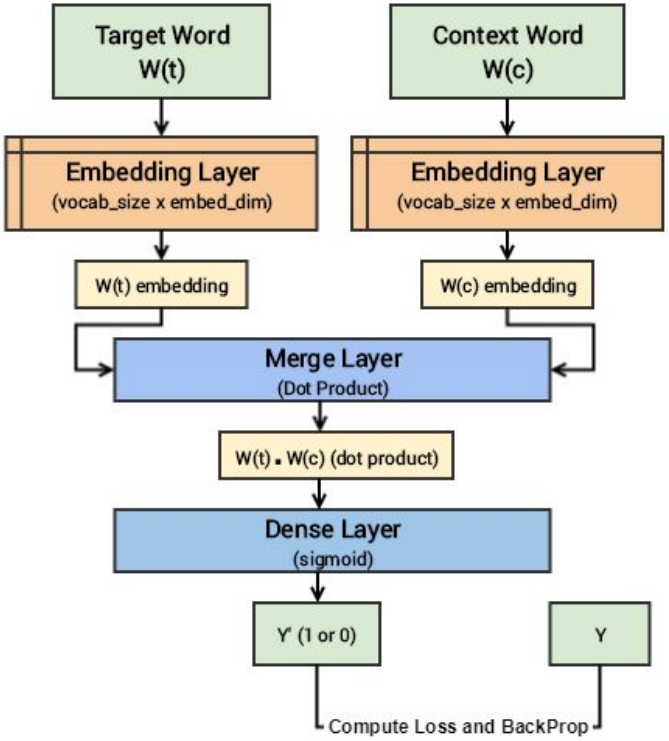

Skip-Gram - Entrenamiento

Skip-Gram requiere más datos para lograr un buen resultado pero obtiene más información sobre el contexto del corpus en sus embeddings.

```
__________________________________________________________________________________________________
Layer (type)                    Output Shape         Param #     
==================================================================================================
merge_2 (Merge)                 (None, 1)            0           
__________________________________________________________________________________________________
dense_3 (Dense)                 (None, 1)            2           
==================================================================================================
Total params: 2,485,002
Trainable params: 2,485,002
Non-trainable params: 0
__________________________________________________________________________________________________
```

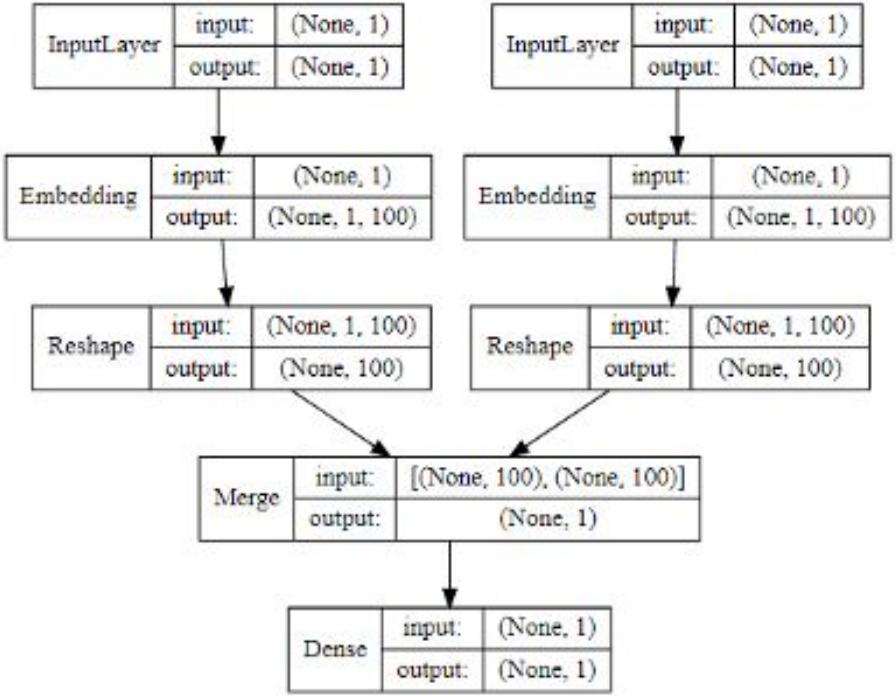

Negative sampling

LINK

En SkipGram/CBOW la cantidad de parámetros a entrenar en la softmax es enorme:

Parametros = vocab_size * embedding_size → millones de parámetros

Vanilla Skip-Gram

W_output (old) − Learning R. × grad_W_output = W_output (new)

Learning R.: 0.05

W_output (old)			grad_W_output			W_output (new)		
-0.560	0.340	0.160	0.064	0.071	-0.014	-0.563	0.336	0.161
-0.910	-0.440	1.560	0.098	0.015	0.063	-0.915	-0.441	1.557
-1.210	-0.130	-1.320	0.069	0.089	0.045	-1.213	-0.134	-1.322
1.670	-0.150	-1.030	0.014	0.085	0.079	1.669	-0.154	-1.034
1.720	-1.460	0.730	-0.021	0.067	0.071	1.721	-1.463	0.726
0.000	1.390	-0.120	-0.098	-0.088	0.091	0.005	1.394	-0.125
-0.060	1.520	-0.790	-0.072	-0.078	-0.089	-0.056	1.524	-0.786
0.800	1.850	-1.670	0.046	-0.079	-0.053	0.798	1.854	-1.667
-1.370	1.320	-0.480	-0.049	-0.087	0.025	-1.368	1.324	-0.481
0.670	1.990	-1.850	-0.060	0.092	0.042	0.673	1.985	-1.852
-1.520	-1.740	-1.860	0.074	0.050	0.070	-1.524	-1.743	-1.864
(11X3)			(11X3)			(11X3)		

aegis4048.github.io

Negative Sampling

W_output (old) − Learning R. × grad_W_output = W_output (new)

Learning R.: 0.05

W_output (old)			grad_W_output			W_output (new)		
-0.560	0.340	0.160	Not computed!			-0.560	0.340	0.160
-0.910	-0.440	1.560				-0.910	-0.440	1.560
-1.210	-0.130	-1.320				-1.210	-0.130	-1.320
1.670	-0.150	-1.030				1.670	-0.150	-1.030
1.720	-1.460	0.730				1.720	-1.460	0.730
0.000	1.390	-0.120				0.000	1.390	-0.120
-0.060	1.520	-0.790				-0.060	1.520	-0.790
0.800	1.850	-1.670	Positive sample, w_o	0.031	0.030	0.041	0.798	1.849	-1.672
-1.370	1.320	-0.480	Negative sample, k=1	-0.090	0.031	-0.065	-1.366	1.318	-0.477
0.670	1.990	-1.850	Negative sample, k=2	0.056	0.098	-0.061	0.667	1.985	-1.847
-1.520	-1.740	-1.860	Negative sample, k=3	0.069	0.084	-0.044	-1.523	-1.744	-1.858
(11X3)				(11X3)			(11X3)		

aegis4048.github.io

En cada iteración se observa la palabras [target, contexto] y "K" palabras aleatorias del corpus.

El objetivo es optimizar cómputo aproximando la softmax. Además funciona como regularización. Para corpus pequeños, el muestreo debe ser mayor.

Visualizar embeddings en baja dimensionalidad:

t-SNE (t-distributed stochastic neighbor embedding)

LINK

- Técnica de reducción de dimensionalidad no-lineal (a diferencia de PCA).
- Intenta reproducir en baja dimensionalidad, la localidad de los datos en alta dimensionalidad.
- Es estocástica, a priori los resultados no se repiten.
- Por su carácter estocástico es sólo recomendable como herramienta de visualización y exploratoria.

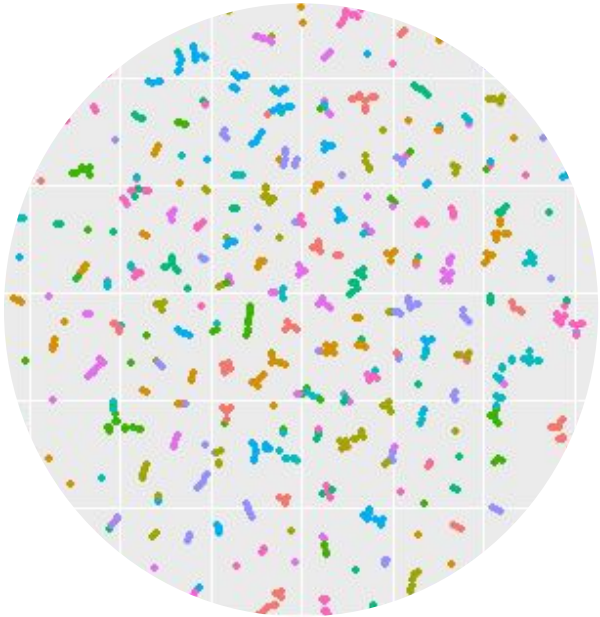

Intervalo

Gensim - Doc2Vec paragraph embeddings

LINK

Utilizaremos esta librería que nos facilita generar embeddings tipo Skip-Gram o CBOW de nuestros corpus

GENSIM
topic modelling for humans

- Librería de Python
- Existe desde 2009 y nació originalmente para topic modelling
- Muy popular y muy simple de utilizar

Generación de embeddings con Gensim

Colab 2.b

Desafío

Crear sus propios vectores con Gensim basado en lo visto en clase con otro dataset.
Probar términos de interés y explicar similitudes en el espacio de embeddings.
Intentar plantear y probar tests de analogías. Graficar los embeddings resultantes.
Sacar conclusiones.

Algunos recursos para descargar corpora de texto

Project Gutenberg	Compilación de literatura completa de dominio público principalmente en inglés.
Textos.info	Compilación de literatura completa de dominio público en español.

BERT y transformers

¿Qué cambió? El modelo ya no lee palabra por palabra de forma aislada. Mira la frase **entera**.

Innovación: El "Embedding" ya no se busca en una tabla fija; se **calcula en tiempo real** dependiendo de las palabras vecinas.

Evolución de embeddings

Sentence embeddings: ¿Cómo representamos una idea completa?

No es solo sumar palabras: No basta con sumar los vectores de "No", "es", "bueno". El orden y la estructura importan.

¿Qué son? Son vectores que representan el significado global de una oración o un párrafo entero.

Embeddings multimodales

OpenAI CLIP

¿Y si usamos el **mismo mapa para palabras y para fotos**?

¿Cómo funciona? El modelo se entrena con millones de imágenes y sus leyendas. Aprende que el vector de la foto de un perro debe estar en el mismo lugar que el vector de la palabra "perro".

Aplicaciones

Recomendaciones

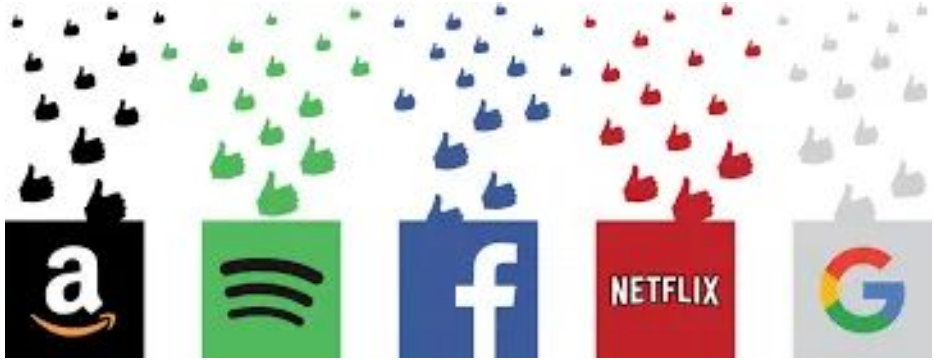

Buscadores

Base de LLMs